

I.S.P. KHIPU

INFORME TÉCNICO FINAL

Khipu CRM Académico-Comercial: seguimiento inteligente de postulantes, alumnos, aliados y proyectos

Documento	<u>Proyecto final integrador</u>
Alumna	<u>Bayona Valdez, Fany</u>
Curso	<u>Desarrollo de Sistemas Inteligentes II</u> <u>(2025-2)</u>
Docente	<u>Poma Enríquez, Genaro Raúl</u>
Ciclo	<u>2025-2 · Sesión de cierre</u>

Cusco, Perú · setiembre de 2026

1. Resumen ejecutivo

Las áreas de Admisión, Convenios e InkaLab del Instituto Superior Privado Khipu pierden oportunidades de conversión (postulantes, colegios, empresas y aliados) porque su información de contactos e interacciones está dispersa en hojas de cálculo, WhatsApp, correos y agendas personales: no existe un mecanismo que priorice automáticamente a los contactos con mayor probabilidad de conversión ni que alerte sobre seguimientos atrasados.

Este proyecto entrega una aplicación web inteligente que resuelve ese problema: un CRM institucional con **scoring predictivo de conversión** (machine learning), **clasificación automática de mensajes** (NLP, KhipuBot) y **alertas de seguimiento**, cubierto por pruebas automatizadas y desplegado en staging. Indicadores clave del sistema:



2. Arquitectura del sistema

Aplicación web de tres capas con el módulo de IA desacoplado lógicamente. La interfaz web (HTML/CSS/JS + Chart.js) consume una API REST protegida por JWT; el backend FastAPI gestiona el CRM y orquesta la inferencia; los modelos entrenados viven como artefactos versionados en Git y se sirven con carga singleton. La base de datos es SQLite en desarrollo y PostgreSQL en el despliegue (SQLAlchemy abstrae el motor).

Capa	Tecnología	Responsabilidad
Interfaz web	HTML/CSS/JS vanilla · Chart.js	Login, dashboard con embudo, contactos, oportunidades con score, tareas, alertas y KhipuBot
API / Backend	Python · FastAPI · SQLAlchemy	25+ endpoints REST documentados en Swagger; JWT con 4 roles; validación Pydantic
Módulo de IA	scikit-learn (TF-IDF, LogReg, RandomForest)	Scoring predictivo, clasificación NLP de mensajes y recomendación de próxima acción
Datos	SQLite (dev) · PostgreSQL (staging)	Contactos, interacciones, oportunidades, campañas, tareas y usuarios

Tabla 1. Capas de la arquitectura y su responsabilidad.

3. Modelo de inteligencia artificial

3.1 Scoring predictivo de conversión (RF02)

Problema de clasificación binaria: dado el comportamiento de una oportunidad, ¿se convertirá (matrícula o convenio firmado)? Se entrenó con 4,000 registros sintéticos que simulan el histórico centralizado (44.5% de conversión), con variables operativas: tipo de contacto, canal de origen, etapa del embudo, número de interacciones, tiempo promedio de respuesta y días sin interacción.

Preparación de datos (documentada en ml/train_scoring.py):

Tarea	Tratamiento aplicado	Cantidad
Limpieza de duplicados	Filas heredadas de hojas de cálculo eliminadas por id de contacto	20
Tratamiento de outliers	Tiempos de respuesta > 720 h convertidos a nulos (dato irrecuperable)	46
Imputación de nulos	Mediana del tiempo de respuesta (imputer del pipeline)	245
Codificación	One-hot para categóricas (tipo, canal, etapa)	—
Normalización	Estandarización z-score de variables numéricas	—

Tabla 2. Preparación de datos previa al entrenamiento.

Con split estratificado 75/25 (seed fija) se compararon dos candidatos; se seleccionó **Regresión Logística** por mayor F1 y ROC-AUC, y por interpretabilidad: sus coeficientes confirman que respuestas rápidas, más interacciones y etapas avanzadas elevan la probabilidad de conversión — coherente con el negocio y explicable a los usuarios de Admisión y Convenios.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresión Logística (seleccionado)	0.822	0.814	0.777	0.795	0.902
Random Forest (300 árboles)	0.811	—	—	0.780	0.886

Tabla 3. Evaluación en test. Matriz de confusión: VN 476, FP 79, FN 99, VP 346.

3.2 Clasificación NLP — KhipuBot (RF01)

Clasificador de mensajes entrantes en cinco tipos de contacto (TF-IDF con n-gramas 1-2 + Regresión Logística), entrenado con 2160 mensajes simulados que incluyen ~8% de mensajes ambiguos con etiqueta aleatoria, para reproducir el ruido real de un canal multicanal. Resultado en test (540 mensajes): accuracy **94.4%** y F1 macro **0.945**. La API devuelve la confianza de la predicción; por debajo de 0.5 la interfaz marca el caso para revisión manual.

Tipo de contacto	aliado	colegio	egresado	empresa	postulante
F1-score	0.945	0.933	0.949	0.930	0.967

Tabla 4. Métricas del clasificador NLP por tipo de contacto.

3.3 Recomendación de próxima acción

Módulo heurístico que traduce el score en una acción operativa concreta (agendar entrevista de cierre, llamar y enviar información, reactivar con campaña o evaluar cierre como perdido), cruzando la probabilidad con los días sin interacción (urgencia). El score se persiste en la oportunidad y alimenta el dashboard.

4. Pruebas

40 pruebas automatizadas con pytest, todas aprobadas en ~1.2 s: 11 unitarias del modelo (umbrales mínimos de métricas, coherencia de predicciones, clasificación por clase y rendimiento: 100 scores en menos de 3 s, RNF02) y 29 funcionales de la API (login y JWT, control de roles, CRUD completo, interacciones, scoring persistido, KhipuBot, tareas, alertas, dashboard y códigos de error 401/403/404/422). Además, 2 pruebas de regresión validan que las páginas web carguen sus dependencias JavaScript.

```
$ python -m pytest tests/ -q
40 passed, 2 warnings in 1.15s
# Las 2 advertencias son deprecations internas de starlette/anyio;
# no afectan los resultados.
```

5. Seguridad aplicada

- **Validación de entradas:** esquemas Pydantic en todos los endpoints de escritura, con dominios restringidos por regex, longitudes máximas y rangos numéricos acotados.
- **Manejo de errores:** mensajes genéricos en login (sin revelar qué campo falló), 404 sin datos internos y sin stack traces al cliente.
- **Credenciales:** SECRET_KEY y conexión de base de datos por variables de entorno; .env excluido del repositorio; contraseñas con PBKDF2-HMAC-SHA256 (120 000 iteraciones) y comparación resistente a timing attacks.
- **Control de acceso (RNF01):** JWT con expiración y jerarquía de roles lector < admisión < gestor < admin, verificada por pruebas (403).
- **Frontend:** escapado de todo contenido dinámico contra XSS y cierre de sesión que elimina el token.

El detalle completo, con la verificación de cada práctica, está en el checklist de seguridad (documento adjunto).

6. Despliegue

El sistema se despliega como contenedor Docker (Dockerfile + docker-compose con PostgreSQL) y en Render mediante el blueprint render.yaml (web service + PostgreSQL gestionado, healthcheck en /health). La documentación de la API queda disponible en /docs (Swagger autogenerado) en cualquier entorno. URL de staging: <https://khipu-crm.onrender.com>.

7. Conclusiones

- Se cumplió el objetivo: un CRM web funcional cuyo diferencial de IA no solo almacena datos, sino que prioriza contactos y sugiere acciones concretas de seguimiento.
- El modelo de scoring alcanza 0.902 de ROC-AUC con seis variables operativas sencillas, lo que lo hace explicable y fácil de adoptar.
- El cuello de botella identificado es la calidad del dato: centralizar las interacciones es condición para que el scoring aporte valor (como anticipó la fase de preparación de datos).
- Trabajo futuro: reentrenar periódicamente con datos reales, integrar WhatsApp Business API para KhipuBot (Zapier o n8n como puente), y conectar con la cartera DTA (Khipu DataBoard, Khipu ID).